



UNGDOMMENS NATURVIDENSKABELIGE FORENING

Fuld Intro til Transformers

Hvordan ord lærer at lytte til hinanden — helt uden matricer



- Hvert ord er nu en **vektor** i et latent rum (en embedding).
- Ens ord ligger tæt; man kan endda regne med mening (konge – mand $\approx$ dronning – kvinde).
- Men indtil nu er hvert ord alene. I dag lærer de at **tale sammen**.

Matematik-varsel: Ingen matrix-regning i dag. Vi holder os til idéen — “hvem lytter til hvem”.



“Ridderen tog sit skarpe _____”

- For at gætte næste ord skal modellen vide, hvilke *tidligere* ord der betyder mest.
- “skarpe” peger stærkt mod *sværd*. “sit” gør ikke.
- Vi vil lade hvert ord **selv vælge**, hvad det lytter til. Det hedder **attention**.

Ikke en fast kæde som Markov — men et frit valg, ord for ord.



Attention — ét trin ad gangen



To små kort til hvert ord

Ud af hvert ords vektor laver modellen to ting:

Key — “hvad jeg tilbyder”

Et lille skilt hvert ord holder op: *“jeg handler om et våben”*.


Query — “hvad jeg leder efter”

Det nuværende ords spørgsmål: *“findes der et våben før mig?”*

*Som en søgning: **query** = søgeord, **key** = mærkat på hvert ord.*




Kun query: et spørgsmål uden svar



Har vi kun et spørgsmål og ingen mærkater, kan vi ikke vælge — alt vejer ens.




Kun key: mærkater, men ingen der spørger



Ordene “råber” hvad de er — men uden et spørgsmål ved vi ikke, hvad vi skal bruge.



Query MØDER key: nu er der match




Passer query og key sammen → højt match-tal. “skjold” vinder her.

Match-tallet kan være hvad som helst — store, små, negative. Det rydder vi op i nu.




Regularisering: gør point til pæne vægte (softmax)



Softmax presser alle match-tal om til vægte mellem 0 og 1, der summer til 100 %.



Skalering: hold vægtene i ro




- Bliver match-tallene for store, bliver softmax knivskarp: ét ord får alt, resten intet.
- Vi **skalerer dem ned** først, så fordelingen bliver blødere.
- Så kan modellen stadig lære — i stedet for at låse sig fast for tidligt.

Skalering = lydstyrke-knap, så ingen enkelt stemme overdøver resten.



Fuldt ud: hvem lytter til hvem



- Hvert ord (række) fordeler sin opmærksomhed på tidligere ord (søjler).
- Mørk = “jeg lytter meget her”.
- Bemærk trekanten: et ord kan kun se *bagud* — ikke ind i fremtiden.

Det er hele attention: query, key, match, softmax, skalering. Færdig.



Ikke kun ord



Attention virker på alt, der kommer i dele

- Vi brugte ord — men “dele der skal vælge, hvem de lytter til” passer på meget mere.
- **Billeder:** små felter, der lytter til hinanden (Vision Transformers).
- **Proteiner, musik, kode:** samme mekanisme, andre “ord”.

Attention er ikke en sprog-ting. Det er en generel måde at lade dele samarbejde.



Fra teori til det I skal lege med



GPT-2: den store lillebror til ChatGPT

- **GPT** = stak af attention-lag, trænet på én simpel opgave: *gæt næste tegn*.
- GPT-2 (2019) var det første, der skrev overbevisende afsnit — forfaderen til ChatGPT.
- Jeres model i workshoppen er en **lille** GPT: samme idé, få lag, kører i Colab.

Samme opskrift som de store — bare skrumpet så den kan køre på en formiddag.



Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Łukasz Kaiser*
Google Brain
lukaszkaiser@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com

- Ældre sprogmodeller slæbte rundt på en lang hukommelses-kæde. Papiret sagde: smid kæden væk.
- **Attention alene** er nok — lad ordene vælge selv.
- Alt hvad I lige har set, står i det ene papir. Og det driver hele AI-bølgen i dag.




Nu er det jeres tur — byg og finetun en sprogmodel

Nu er det jeres tur ✨

Åbn 06-LLM/2-Transformer-workshop.ipynb og gå i gang med opgaverne.
I får en færdig basis-model og **finetuner** den, så den skifter stil.

Forslag til at eksperimentere:

- Skru på TEMPERATURE (0.2 = forsigtig, 1.3 = vild) og TOP_K.
- Skift FINETUNE_FILE mellem jokes og “rent kaos” — hør sproget skifte.
- Lav jeres eget data (Generate-your-own-data.ipynb) og finetun på det.



Attention is all you need.

Byg jeres egen sprogmodel — og få den til at sige noget vildt.